

# TASS – Projekt 2

Rafał Budnik (318639)  
Kamil Michalak (318695)  
Ireneusz Okniński (310228)

18 stycznia 2026

## Spis treści

|          |                                                                                 |           |
|----------|---------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Cel projektu</b>                                                             | <b>3</b>  |
| <b>2</b> | <b>Źródła danych</b>                                                            | <b>3</b>  |
| 2.1      | Dane Airbnb – Nowy Jork (2019) . . . . .                                        | 3         |
| 2.2      | Dane o przestępczości – NYPD (2006–2019) . . . . .                              | 5         |
| <b>3</b> | <b>Technologia i wykorzystane biblioteki</b>                                    | <b>7</b>  |
| <b>4</b> | <b>Kod źródłowy</b>                                                             | <b>8</b>  |
| <b>5</b> | <b>Metodyka przygotowania cech i łączenia danych</b>                            | <b>8</b>  |
| 5.1      | Przygotowanie danych Airbnb do analizy statystycznej . . . . .                  | 8         |
| 5.2      | Kategoryzacja przestępstw . . . . .                                             | 9         |
| 5.3      | Łączenie przestrzenne danych . . . . .                                          | 9         |
| <b>6</b> | <b>Analiza eksploracyjna i przestrzenna danych</b>                              | <b>10</b> |
| 6.1      | Mapy interaktywne (Folium) . . . . .                                            | 10        |
| 6.2      | Mapy gęstości (Hexbin) . . . . .                                                | 11        |
| 6.3      | Mapa siatkowa . . . . .                                                         | 12        |
| <b>7</b> | <b>Analiza statystyczna</b>                                                     | <b>13</b> |
| 7.1      | Strefy przestępczości (low/mid/high) na podstawie tercylu . . . . .             | 14        |
| 7.1.1    | Strefy oparte na <i>violent</i> . . . . .                                       | 14        |
| 7.1.2    | Strefy oparte na <i>felony</i> . . . . .                                        | 15        |
| 7.2      | Zależności „cena–przestępczość” na wykresach heksagonalnych . . . . .           | 17        |
| 7.3      | Korelacje i zmienne opisujące standard mieszkania . . . . .                     | 19        |
| 7.4      | Standard mieszkania a strefy przestępczości . . . . .                           | 20        |
| 7.5      | Agregacja na poziomie dzielnic (borough join) . . . . .                         | 21        |
| 7.6      | Analiza siatkowa: zależność gęstości Airbnb a gęstości przestępczości . . . . . | 23        |
| 7.7      | Modele regresji . . . . .                                                       | 24        |
| 7.7.1    | Model bazowy . . . . .                                                          | 24        |
| 7.7.2    | Model rozszerzony . . . . .                                                     | 25        |
| 7.7.3    | Interpretacja wyników . . . . .                                                 | 25        |

|          |                                                        |           |
|----------|--------------------------------------------------------|-----------|
| <b>8</b> | <b>Analiza sieciowa</b>                                | <b>25</b> |
| 8.1      | Hotspoty przestępczości (agregacja siatkowa) . . . . . | 25        |
| 8.2      | Graf dwudzielny Airbnb-hotspot . . . . .               | 26        |
| 8.3      | Projekcja hotspotów . . . . .                          | 26        |
| 8.4      | Miary centralności hotspotów . . . . .                 | 26        |
| 8.5      | Detekcja społeczności (community detection) . . . . .  | 27        |
| 8.6      | Wizualizacje sieci i społeczności . . . . .            | 27        |
| 8.7      | Interpretacja wyników analizy sieciowej . . . . .      | 29        |
| <b>9</b> | <b>Podsumowanie i wnioski</b>                          | <b>30</b> |

# 1 Cel projektu

Celem projektu jest porównanie lokalizacji ofert Airbnb z informacjami o zdarzeniach kryminalnych na przykładzie Nowego Jorku oraz analiza zależności pomiędzy poziomem przestępczości a cenami i rozmieszczeniem ofert krótkoterminowego najmu.

## 2 Źródła danych

### 2.1 Dane Airbnb – Nowy Jork (2019)

Źródłem danych dotyczących ofert Airbnb jest zbiór *New York City Airbnb Open Data*, dostępny na platformie *Kaggle*:

<https://www.kaggle.com/datasets/dgomonov/new-york-city-airbnb-open-data>.

#### Wykorzystane kolumny

Zestawienie kolumn wykorzystanych w analizie danych Airbnb przedstawiono w Tab. 1:

Tabela 1: Kolumny zbioru danych Airbnb wykorzystane w analizie.

| Nazwa kolumny       | Typ      | Opis                                                                                 |
|---------------------|----------|--------------------------------------------------------------------------------------|
| id                  | liczbowy | Unikalny identyfikator oferty Airbnb.                                                |
| name                | tekst    | Nazwa ogłoszenia nadana przez gospodarza.                                            |
| host_id             | liczbowy | Identyfikator gospodarza (hosta).                                                    |
| host_name           | tekst    | Imię gospodarza.                                                                     |
| neighbourhood_group | tekst    | Dzielnica (borough) Nowego Jorku: Manhattan, Brooklyn, Queens, Bronx, Staten Island. |
| latitude            | float    | Szerokość geograficzna oferty.                                                       |
| longitude           | float    | Długość geograficzna oferty.                                                         |
| room_type           | tekst    | Typ zakwaterowania (np. Entire home/apt, Private room, Shared room).                 |
| price               | liczbowy | Cena za noc (USD).                                                                   |
| minimum_nights      | liczbowy | Minimalna liczba nocy wymagana przy rezerwacji.                                      |
| number_of_reviews   | liczbowy | Liczba recenzji oferty.                                                              |
| last_review         | data     | Data ostatniej recenzji.                                                             |
| reviews_per_month   | float    | Średnia liczba recenzji na miesiąc.                                                  |
| availability_365    | liczbowy | Liczba dni w roku, w których oferta jest dostępna.                                   |

#### Czyszczenie danych

Wstępne czyszczenie zbioru Airbnb obejmowało następujące kroki:

- ograniczenie danych do wybranych kolumn istotnych dla analizy,
- usunięcie rekordów z brakami danych w kluczowych kolumnach: `neighbourhood_group`, `latitude`, `longitude`, `room_type`, `price`,
- odfiltrowanie współrzędnych spoza granic Nowego Jorku (przybliżone ograniczenie prostokątne),

- ograniczenie ofert do tych, które posiadały aktywność recenzencką w okresie analizy:  $\text{last\_review} \geq 2018-01-01$ .

### Statystyki po oczyszczeniu

- Liczba ofert: **31 259**
- Średnia cena: ok. **141 USD**
- Mediana ceny: ok. **102 USD**
- Zakres cen: **0 – 8 500 USD**
- Średnia liczba recenzji: **34,7**
- Maksymalna liczba recenzji: **629**

### Rozkład ofert według dzielnic

Liczbę ofert Airbnb w podziale na dzielnice Nowego Jorku przedstawiono w Tab. 2:

Tabela 2: Rozkład liczby ofert Airbnb według dzielnic Nowego Jorku.

| Dzielnica     | Liczba ofert |
|---------------|--------------|
| Brooklyn      | 13 141       |
| Manhattan     | 12 952       |
| Queens        | 4 046        |
| Bronx         | 817          |
| Staten Island | 303          |


### Typy pokoi

Strukturę ofert Airbnb ze względu na typ oferowanego zakwaterowania zaprezentowano w Tab. 3:

Tabela 3: Liczba ofert Airbnb według typu pokoju.

| Typ pokoju      | Liczba ofert |
|-----------------|--------------|
| Entire home/apt | 16 340       |
| Private room    | 14 198       |
| Shared room     | 721          |

## Rozmieszczenie przestrzenne danych



Rysunek 1: Gęstość przestrzenna ofert Airbnb.

## 2.2 Dane o przestępczości – NYPD (2006–2019)

Drugim źródłem danych jest zbiór *NYPD Crime Complaint Data Historic*, dostępny na Kaggle:

<https://www.kaggle.com/datasets/brunacmendes/nypd-complaint-data-historic-20062019>.

### Wykorzystane kolumny

Zestawienie kolumn zbioru danych NYPD wykorzystanych w analizie przedstawiono w Tab. 4:

Tabela 4: Kolumny zbioru danych NYPD wykorzystane w analizie.

| Nazwa kolumny  | Typ            | Opis                                      |
|----------------|----------------|-------------------------------------------|
| complaint_id   | tekst/liczbowy | Unikalny identyfikator zgłoszenia.        |
| complaint_date | data           | Data zgłoszenia/zdarzenia (CMPLNT_FR_DT). |

|                     |       |                                                                       |
|---------------------|-------|-----------------------------------------------------------------------|
| borough             | tekst | Dzielnica NYC, np. MANHATTAN, BROOKLYN, QUEENS, BRONX, STATEN ISLAND. |
| law_category        | tekst | Kategoria prawna przestępstwa: FELONY, MISDEMEANOR, VIOLATION.        |
| offense_description | tekst | Opis typu przestępstwa (OFNS_DESC), np. ROBBERY, BURGLARY.            |
| latitude            | float | Szerokość geograficzna zdarzenia.                                     |
| longitude           | float | Długość geograficzna zdarzenia.                                       |

## Czyszczenie danych

Czyszczenie danych NYPD obejmowało:

- wybór kluczowych kolumn umożliwiających analizę przestrzenną oraz kategoryzację przestępstw,
- ujednolicenie nazewnictwa kolumn (np. CMPLNT\_NUM → `complaint_id`),
- usunięcie rekordów z brakami w kluczowych kolumnach: `complaint_date`, `borough`, `law_category`, `offense_description`, `latitude`, `longitude`,
- ograniczenie danych do lat 2018–2019,
- odfiltrowanie współrzędnych spoza granic Nowego Jorku (przybliżone ograniczenie prostokątne).

## Statystyki po oczyszczeniu

Po przeprowadzeniu procesu czyszczenia zbiorów danych NYPD obejmował łącznie **922 882** zgłoszenia przestępstw. Rozkład liczby zgłoszeń w podziale na lata przedstawiono w Tab. 5:

Tabela 5: Liczba zgłoszeń przestępstw NYPD w latach 2018–2019.

| Rok  | Liczba zgłoszeń |
|------|-----------------|
| 2018 | 472 213         |
| 2019 | 450 669         |


## Kategorie prawne

Strukturę zgłoszeń przestępstw według kategorii prawnej zaprezentowano w Tab. 6:

Tabela 6: Rozkład zgłoszeń przestępstw NYPD według kategorii prawnej.

| Kategoria   | Liczba zgłoszeń |
|-------------|-----------------|
| Misdemeanor | 497 438 (54%)   |
| Felony      | 281 779 (31%)   |
| Violation   | 143 665 (15%)   |

## Rozmieszczenie przestrzenne danych



Rysunek 2: Gęstość przestrzenna popełnionych przestępstw (NYPD).

## 3 Technologia i wykorzystane biblioteki

Dane wykorzystane w projekcie zostały pobrane z platformy *Kaggle* przy użyciu biblioteki *kagglehub*, umożliwiającej automatyczne pobieranie zbiorów danych oraz ich lokalne przechowywanie. Proces ten obejmował również weryfikację obecności plików, co pozwalało uniknąć wielokrotnego pobierania tych samych danych.

Do przetwarzania, analizy oraz wizualizacji danych wykorzystano następujące biblioteki języka Python:

- *pandas* – ładowanie, czyszczenie i przetwarzanie danych tabelarycznych,
- *numpy* – operacje numeryczne oraz obliczenia pomocnicze,
- *matplotlib* – tworzenie wizualizacji statycznych (wykresy, mapy gęstości),
- *folium* – interaktywne wizualizacje przestrzenne i mapy,
- *geopandas* oraz *contextily* – operacje geoprzestrzenne oraz wizualizacja danych na tle map,

- `scikit-learn` – obliczenia przestrzenne (m. in. wyszukiwanie sąsiedztwa punktów w promieniu),
- `statsmodels` – analiza statystyczna oraz modele regresji liniowej,
- `networkx` – budowa i analiza sieci (analiza grafowa, centralności, community detection).

Zastosowany zestaw narzędzi umożliwił przeprowadzenie zarówno analizy eksploracyjnej i statystycznej, jak i analizy przestrzennej oraz sieciowej.

## 4 Kod źródłowy

Kod źródłowy projektu wraz z kompletną dokumentacją znajduje się w repozytorium GitHub:

<https://github.com/Camill0x/TASS-project-2>

Repozytorium zawiera:

- pełny kod źródłowy projektu,
- plik `requirements.txt` określający zależności środowiska,
- plik `README.md` zawierający szczegółową instrukcję uruchomienia projektu oraz opis kolejnych etapów analizy.

Struktura repozytorium oraz dołączona instrukcja umożliwiają pełne odtworzenie przeprowadzonych analiz.

## 5 Metodyka przygotowania cech i łączenia danych

### 5.1 Przygotowanie danych Airbnb do analizy statystycznej

Na potrzeby dalszych analiz statystycznych przygotowano zbiór danych zawierający oferty Airbnb aktywne w okresie analizy. W celu ograniczenia wpływu obserwacji skrajnych na wyniki modeli statystycznych, dokonano dodatkowego przetworzenia danych obejmującego:

- odfiltrowanie ofert o cenach poniżej 10 USD oraz powyżej 1000 USD,
- utworzenie zmiennej `log_price` jako logarytmu naturalnego ceny, w celu stabilizacji wariancji i poprawy własności estymacyjnych modeli regresyjnych.

Po zastosowaniu powyższych filtrów zbiór danych obejmował:

- **31 177** ofert Airbnb,
- średnią cenę na poziomie **136,9 USD**,
- medianę ceny równą **101 USD**.

Tak przygotowany zbiór danych wykorzystano w dalszych analizach ilościowych.



## 5.2 Kategoryzacja przestępstw

W celu lepszego uchwycenia wpływu różnych typów przestępstw na funkcjonowanie rynku krótkoterminowego najmu, przeprowadzono wstępną analizę częstości występowania zdarzeń kryminalnych zgłaszanych przez NYPD w latach 2018–2019. Oczyszczony zbiór danych obejmował 922 882 zgłoszenia.

Analiza rozkładu czasowego wykazała porównywalną liczbę zgłoszeń w obu latach okresu analizy (472 213 w 2018 r. oraz 450 669 w 2019 r.). Największa liczba przestępstw została odnotowana w dzielnicach Brooklyn oraz Manhattan, co jest spójne z ich gęstością zaludnienia i intensywnością aktywności miejskiej.

Pod względem kategorii prawnych dominowały przestępstwa typu *misdemeanor* (54%), następnie *felony* (31%) oraz *violation* (15%). Jednocześnie analiza szczegółowych opisów zdarzeń (OFNS\_DESC) wskazała na znaczną heterogeniczność typów przestępstw.

Wśród najczęściej występujących typów zdarzeń znalazły się m. in. drobne kradzieże (*Petit Larceny*), nękanie (*Harassment*), przestępstwa przeciwko mieniu (*Grand Larceny*, *Burglary*) oraz przestępstwa z użyciem przemocy, takie jak rozboje (*Robbery*) czy napaści (*Felony Assault*).

Na podstawie tej analizy zdefiniowano uproszczoną taksonomię przestępstw, grupując je według ich potencjalnego wpływu na subiektywne poczucie bezpieczeństwa:

- **violent** – przestępstwa o charakterze przemocy (np. rozboje, napaści, gwałty),
- **property** – przestępstwa przeciwko mieniu (np. kradzieże, włamania),
- **other** – pozostałe kategorie przestępstw.

Mapowanie szczegółowych kategorii przestępstw do powyższych grup zostało oparte na najczęściej występujących typach zdarzeń.

## 5.3 Łączenie przestrzenne danych

Ponieważ zbiory danych Airbnb oraz NYPD nie posiadają wspólnych identyfikatorów, relację pomiędzy ofertami a zdarzeniami kryminalnymi zdefiniowano na podstawie ich lokalizacji geograficznej. Zastosowano dwa uzupełniające się podejścia do łączenia danych:

- łączenie w skali administracyjnej (dzielnice miasta),
- łączenie w skali lokalnej na podstawie odległości geograficznej.

### Agregacja przestępstw w otoczeniu ofert Airbnb

Dla każdej oferty Airbnb obliczono liczbę zdarzeń kryminalnych znajdujących się w jej bezpośrednim otoczeniu. W tym celu zastosowano agregację opartą na promieniu geograficznym, wykorzystując współrzędne ofert oraz zdarzeń kryminalnych.

Analizę przeprowadzono dla trzech wartości promienia: 300 m, 400 m oraz 500 m. Pozwoliło to na ocenę stabilności wyników względem przyjętej skali przestrzennej. Dla każdej oferty obliczono m. in.:

- całkowitą liczbę przestępstw w otoczeniu,
- liczbę przestępstw według kategorii prawnych (*felony*, *misdemeanor*, *violation*),

- liczbę przestępstw według zdefiniowanych grup (*violent*, *property*, *other*).

Wynikiem tego etapu był połączony zbiór danych, zawierający cechy przestrzenne przypisane do każdej oferty Airbnb. W wyniku łączenia przestrzennego cechy przestępczości zostały przypisane do 31 259 ofert Airbnb.

### Agregacja siatkowa danych przestrzennych

Dodatkowo zastosowano agregację przestrzenną opartą na regularnej siatce przestrzennej (grid). W tym podejściu obszar miasta podzielono na komórki o stałym rozmiarze, a następnie zliczono w każdej z nich liczbę ofert Airbnb oraz zdarzeń kryminalnych. Liczba obszarów do analizy wyniosła 4 374.

Agregacja siatkowa umożliwiła analizę zależności pomiędzy gęstością ofert a gęstością przestępczości w skali lokalnej, niezależnie od pojedynczych ofert, stanowiąc uzupełnienie analizy opartej na promieniach wokół konkretnych lokalizacji Airbnb.

## 6 Analiza eksploracyjna i przestrzenna danych


Celem analizy eksploracyjnej i przestrzennej było wstępne rozpoznanie, w jakim stopniu rozmieszczenie ofert Airbnb pokrywa się z przestrzennym rozkładem przestępczości w Nowym Jorku oraz czy w obrębie miasta widoczne są obszary o podwyższonym natężeniu zdarzeń kryminalnych. Analiza ta stanowi etap poprzedzający modelowanie statystyczne i analizę sieciową.

### 6.1 Mapy interaktywne (Folium)

W pierwszym kroku wygenerowano interaktywne mapy prezentujące rozmieszczenie punktów Airbnb oraz zdarzeń kryminalnych NYPD. Mapy umożliwiają zbliżanie/oddalanie oraz porównanie warstw danych w tej samej przestrzeni miejskiej. Wygenerowano osobne mapy dla:

- ofert Airbnb,
- wszystkich zdarzeń kryminalnych,
- zdarzeń sklasyfikowanych jako *felony*,
- zdarzeń należących do grupy *violent*.

Dodatkowo utworzono mapę zbiorczą z możliwością przełączania warstw oraz legendą. Takie porównanie umożliwia wizualną ocenę, czy obszary o dużej gęstości ofert Airbnb pokrywają się z obszarami o dużej liczbie zgłoszeń kryminalnych.



Rysunek 3: Mapa zbiorcza - Airbnb oraz NYPD.

## Interpretacja wyników


Analiza map interaktywnych wskazuje na częściowe pokrywanie się obszarów o dużej gęstości ofert Airbnb oraz zdarzeń kryminalnych, szczególnie w centralnych częściach miasta. Jednocześnie należy zauważyć, że dane NYPD charakteryzują się bardzo wysoką gęstością przestrzenną, co w wizualizacjach mapowych objawia się wrażeniem niemal ciągłego „szumu” na obszarze całego miasta.

Zjawisko to wynika w dużej mierze ze specyfiki rejestracji danych kryminalnych przez NYPD, w których lokalizacja zdarzeń często przypisywana jest do skrzyżowań ulic lub odcinków pomiędzy skrzyżowaniami. W efekcie wiele zdarzeń nakłada się przestrzennie lub występuje bardzo blisko siebie, co ogranicza czytelność map punktowych oraz map ciepła przy dużych zakresach przestrzennych.


Dodatkowo, przy analizie obejmującej całe miasto, zastosowana skala kolorów oraz agregacja wizualna mogą utrudniać identyfikację lokalnych różnic w natężeniu przestępczości. W związku z tym mapy interaktywne pełnią przede wszystkim rolę eksploracyjną i diagnostyczną, a nie narzędzie do precyzyjnego porównania intensywności zjawisk.

## 6.2 Mapy gęstości (Hexbin)

W celu uzupełnienia analizy map interaktywnych przygotowano statyczne mapy gęstości w postaci wykresów typu *hexbin*. Wykresy heksagonalne pozwalają lepiej uchwycić zagęszczenie punktów w przestrzeni poprzez agregację danych w komórkach heksagonalnych i przedstawienie natężenia wystąpień w skali logarytmicznej. Dzięki temu możliwe jest porównanie ogólnych wzorców koncentracji zdarzeń bez nadmiernego „zlewania się” punktów.



Rysunek 4: Mapa hexbin – Airbnb



Rysunek 5: Mapa hexbin – NYPD

## Interpretacja wyników


Mapa gęstości ofert Airbnb (Rys. 4) wskazuje na wyraźną koncentrację krótkoterminowego najmu w wybranych obszarach miasta, w szczególności na Manhattanie oraz w północnych i zachodnich częściach Brooklynu. Poza tymi obszarami gęstość ofert znacząco maleje, a w wielu rejonach peryferyjnych obserwuje się jedynie sporadyczne występowanie ogłoszeń.

Z kolei mapa gęstości wszystkich zgłoszeń kryminalnych NYPD (Rys. 5) charakteryzuje się znacznie bardziej jednorodnym rozkładem przestrzennym. Wysoka liczba zgłoszeń występuje na niemal całym obszarze miasta, co skutkuje wizualnym efektem „szumu” i utrudnia jednoznaczną identyfikację lokalnych różnic w natężeniu przestępczości na podstawie samej wizualizacji, jak to było wspomniane w poprzednim punkcie analizy.

Porównanie obu map wskazuje, że obszary o wysokiej gęstości ofert Airbnb stanowią podzbiór obszarów o wysokiej liczbie zgłoszeń kryminalnych, jednak zależność ta nie ma charakteru symetrycznego. Może to sugerować, że rynek krótkoterminowego najmu preferuje lokalizacje o określonym profilu urbanistycznym i funkcjonalnym, nawet jeśli ogólny poziom zgłoszeń kryminalnych w mieście jest wysoki.

## 6.3 Mapa siatkowa

Rys. 6 przedstawia wizualizację siatkową, w której gęstość zgłoszeń NYPD oznaczono kolorem czerwonym, natomiast gęstość ofert Airbnb kolorem niebieskim:



Rysunek 6: Mapa siatkowa - Airbnb i NYPD.

## Interpretacja wyników

Analiza mapy siatkowej wskazuje, że wysoka gęstość zgłoszeń kryminalnych występuje na znacznej części obszaru miasta, co potwierdza wcześniejsze obserwacje dotyczące „szumu” w danych punktowych. Jednocześnie koncentracja ofert Airbnb jest wyraźnie bardziej selektywna przestrzennie i ogranicza się do wybranych obszarów, głównie centralnych części Manhattanu oraz niektórych rejonów Brooklynu.

Porównanie obu warstw sugeruje, że intensywny rynek krótkoterminowego najmu funkcjonuje przede wszystkim w obszarach o wysokiej aktywności miejskiej, które jednocześnie charakteryzują się podwyższoną liczbą zgłoszeń kryminalnych. Zależność ta nie ma jednak charakteru symetrycznego: wiele obszarów o wysokiej liczbie zgłoszeń NYPD nie wykazuje porównywalnej gęstości ofert Airbnb. Wskazuje to na selektywny charakter lokalizacji rynku Airbnb oraz uzasadnia dalszą analizę ilościową, w której uwzględniono zarówno natężenie, jak i charakter przestępczości.

## 7 Analiza statystyczna

Celem analizy statystycznej było ilościowe zbadanie zależności pomiędzy lokalnym poziomem przestępczości a cenami ofert Airbnb, z uwzględnieniem:

- charakteru przestępstw,
- standardu zakwaterowania (zmienne proxy: typ pokoju, liczba recenzji, dostępność),
- lokalizacji administracyjnej (*borough*).

Analizę przeprowadzono dla promienia  $R = 400$  m, a dane wejściowe ograniczono do ofert o cenach 10-1000 USD; utworzono również zmienną `log_price` w celu stabilizacji wariancji.



## 7.1 Strefy przestępczości (low/mid/high) na podstawie tercylu

W celu porównania poziomu cen w obszarach o różnym natężeniu przestępczości, skonstruowano zmienne stref *crime zones* oparte na tercylach liczby zdarzeń w promieniu 400 m. Zastosowano dwie definicje stref:


- `crime_zone_violent` — tercyle na podstawie liczby zdarzeń z grupy `violent_400m`,
- `crime_zone_felony` — tercyle na podstawie liczby zdarzeń `felonies_400m`.

### 7.1.1 Strefy oparte na *violent*


Wyniki podsumowania stref pokazano w Tab. 7. Mediana ceny rośnie wraz ze strefą: 100 USD (low), 105 USD (mid), 110 USD (high). Jednocześnie średnia liczba zdarzeń `violent` wzrasta od ok. 111 (low) do ok. 625 (high), co potwierdza poprawność konstrukcji stref. Rozkłady cen w strefach przedstawiono na boxplotach (Rys. 7 i 8). Boxploty pozwalają ocenić nie tylko przesunięcie median, ale również różnice w rozproszeniu cen pomiędzy strefami (bez wpływu skrajnych obserwacji, ponieważ outliery zostały ukryte).

Tabela 7: Statystyki cen ofert Airbnb według stref przestępczości opartej na liczbie przestępstw `violent`.

| Strefa  | <i>n</i> | Śr. cena | Mediana | log(cena) | Violent (śr. liczba) | Śr. Ogółem |
|---------|----------|----------|---------|-----------|----------------------|------------|
| Niska   | 10 294   | 127,94   | 100     | 4,639     | 110,54               | 735,61     |
| Średnia | 10 290   | 138,50   | 105     | 4,713     | 287,60               | 1 687,22   |
| Wysoka  | 10 593   | 143,91   | 110     | 4,757     | 624,70               | 2 881,15   |



Rysunek 7: Boxplot - cena w zależności od strefy częstości przestępstw `violent`.



Rysunek 8: Boxplot - logarytm ceny w zależności od strefy częstości przestępstw violent.

## Interpretacja wyników


Zaobserwowany wzrost mediany ceny wraz ze wzrostem natężenia przestępczości sugeruje, że surowa korelacja między „więcej przestępstw” a „wyższa cena” występuje w danych. Jednakże, wyższe ceny w strefach o większym natężeniu przestępczości nie oznaczają, że przestępczość podnosi ceny; bardziej prawdopodobne jest, że czynniki trzecie (np. atrakcyjność turystyczna, centralność lokalizacji, typ zabudowy) jednocześnie zwiększają liczbę ofert i przestępstw.

### 7.1.2 Strefy oparte na *felony*


W przypadku stref opartych na *felony* różnice cenowe są silniejsze (Tab. 8). Mediana ceny wynosi 90 USD (low), 99 USD (mid) oraz 134 USD (high), a średnia cena w strefie wysokiej jest wyraźnie większa (ok. 166 USD). Różnice te wizualizują boxploty (Rys. 9, 10). Wynik sugeruje, że obszary o wysokiej liczbie przestępstw typu *felony* mogą pokrywać się z obszarami silnie zurbanizowanymi i atrakcyjnymi (centra aktywności), gdzie ceny ofert są wysokie mimo intensywnej rejestracji zdarzeń kryminalnych.

Tabela 8: Statystyki cen ofert Airbnb według stref przestępczości opartej na liczbie przestępstw typu *felony*

| Strefa  | <i>n</i> | Śr. cena | Mediana | log(cena) | Felony (śr. liczba) | Śr. Ogółem |
|---------|----------|----------|---------|-----------|---------------------|------------|
| Niska   | 10 306   | 117,50   | 90      | 4,560     | 216,60              | 686,12     |
| Średnia | 10 289   | 126,49   | 99      | 4,641     | 507,59              | 1 601,53   |
| Wysoka  | 10 582   | 165,77   | 134     | 4,904     | 967,39              | 3 014,99   |



Rysunek 9: Boxplot - cena w zależności od strefy częstości przestępstw felony.



Rysunek 10: Boxplot - logarytm ceny w zależności od strefy częstości przestępstw felony.




## Interpretacja wyników


W przypadku stref opartych na liczbie przestępstw typu *felony* obserwowane różnice cenowe są wyraźniejsze niż dla stref opartych na przestępstwach typu *violent*. Rozkłady cen w strefie wysokiej charakteryzują się nie tylko wyższym położeniem mediany, lecz także większym zróżnicowaniem, co wskazuje na współwystępowanie bardzo drogiej oferty z ofertami relatywnie tańszymi. Podobnie jak w przypadku stref opartych na *violent*, zaobserwowane zależności należy interpretować jako korelacje, a nie związki przyczynowe.

## 7.2 Zależności „cena–przestępczość” na wykresach heksagonalnych


Na Rys. 11 przedstawiono zależność `log_price` od `crimes_total_400m`, natomiast na Rys. 12 i 13 analogicznie dla `violent_400m` oraz `felonies_400m`. Wizualizacje te umożliwiają sprawdzenie, czy (i gdzie) występuje trend monotoniczny, oraz czy relacja jest liniowa w przybliżeniu.



Rysunek 11: Hexbin - logarytm ceny w zależności od ogólnej liczby przestępstw w promieniu 400m.



Rysunek 12: Hexbin - logarytm ceny w zależności od liczby przestępstw *violent* w promieniu 400m.




Rysunek 13: Hexbin - logarytm ceny w zależności od liczby przestępstw *felony* w promieniu 400m.

## Interpretacja wyników

Wykresy heksagonalne nie wskazują na silną ani jednoznacznie monotoniczną zależność pomiędzy logarytmem ceny a natężeniem przestępczości. Największa koncentracja obserwacji występuje przy niskich i średnich poziomach przestępstw, gdzie ceny są silnie zróżnicowane. Dla przestępstw ogółem oraz *felony* widoczny jest jedynie słaby, nieliniowy trend dodatni, natomiast w przypadku *violent* zależność jest najslabsza.

### 7.3 Korelacje i zmienne opisujące standard mieszkania

Następnie obliczono macierz korelacji dla zestawu zmiennych obejmujących: `price`, `log_price`, `number_of_reviews`, `reviews_per_month`, `availability_365` oraz miary przestępczości w promieniu 400 m (m. in. `crimes_total_400m`, `felonies_400m`, `violent_400m`, `property_400m` itd.). Wynik przedstawiono w postaci mapy ciepłej (Rys. 14):



Rysunek 14: Macierz korelacji dla podanych zmiennych.

Celem tej części jest identyfikacja:

- czy miary przestępczości są wzajemnie silnie skorelowane (ryzyko współliniowości),
- czy zmienne „standardu” (`reviews`, `availability`) wnoszą niezależną informację o cenie,

- czy relacja „cena–przestępczość” różni się zależnie od typu przestępstwa (np. *violent* vs *felony*).


## Interpretacja wyników

Miary przestępczości w promieniu 400 m są bardzo silnie wzajemnie skorelowane, co wskazuje na ich współliniowość. Zmienne opisujące „standard” mieszkania (`number_of_reviews`, `reviews_per_month`, `availability_365`) wykazują słabe korelacje z ceną, sugerując, że wnoszą informację w dużej mierze niezależną od poziomu cen. Korelacje pomiędzy ceną (oraz `log_price`) a miarami przestępczości są dodatnie, lecz umiarkowane i nie różnią się istotnie pomiędzy typami przestępstw (*violent*, *felony*, *property*).


## 7.4 Standard mieszkania a strefy przestępczości

Przygotowano przekrojowe podsumowania dla kombinacji stref przestępczości i typu pokoju. Zestawiono m. in. średnie i mediany cen oraz miary „opinii/aktywności” (`number_of_reviews`, `reviews_per_month`) i dostępności (`availability_365`).

Dodatkowo przedstawiono średnią `log_price` w strefach *violent* dla poszczególnych `room_type` na wykresie liniowym (Rys. 15, analogicznie dla stref *felony* - rys. 16). Taka forma pozwala zobaczyć, czy różnice pomiędzy strefami wynikają z samej przestępczości, czy raczej z innej struktury typów zakwaterowania (np. przewaga *Entire home/apt* w określonych lokalizacjach).



Rysunek 15: Średni logarytm ceny dla różnych rodzajów zakwaterowań w zależności od strefy ilościowej przestępstw typu *violent*.



Rysunek 16: Średni logarytm ceny dla różnych rodzajów zakwaterowań w zależności od strefy ilościowej przestępstw typu *felony*.

### Interpretacja wyników

We wszystkich strefach przestępczości najwyższe średnie ceny dotyczą ofert typu *Entire home/apt*, a najniższe — *Shared room*, co wskazuje na silny wpływ typu zakwaterowania na poziom cen. Dla każdego *room\_type* obserwowany jest wzrost średniego *log\_price* wraz ze wzrostem natężenia przestępczości, zarówno w strefach *violent*, jak i *felony*. Zależność ta sugeruje, że wcześniej obserwowany związek ceny z przestępczością nie wynika wyłącznie ze zmiany struktury typów zakwaterowania pomiędzy strefami.

## 7.5 Agregacja na poziomie dzielnic (borough join)


W celu odniesienia wyników lokalnych do skali administracyjnej, wykonano agregację ofert Airbnb i zdarzeń NYPD według dzielnic oraz połączono tabele po nazwie dzielnicy. Podsumowanie pokazano w Tab. 9. Najwięcej ofert znajduje się w Brooklynie (13 141) oraz na Manhattanie (12 952), przy jednocześnie wysokich liczbach zgłoszeń NYPD w tych dzielnicach.

Tabela 9: Podsumowanie ofert Airbnb i przestępczości według dzielnic Nowego Jorku.


| Dzielnica     | Oferty | Śr. cena | Mediana | Przestępstwa | Felony | Violent |
|---------------|--------|----------|---------|--------------|--------|---------|
| Brooklyn      | 13 141 | 121,31   | 95      | 268 702      | 87 381 | 55 962  |
| Manhattan     | 12 952 | 181,61   | 145     | 230 467      | 72 050 | 40 972  |
| Queens        | 4 046  | 93,22    | 70      | 182 585      | 57 720 | 38 952  |
| Bronx         | 817    | 79,54    | 65      | 201 339      | 55 202 | 51 127  |
| Staten Island | 303    | 86,83    | 72      | 39 789       | 9 426  | 6 687   |

Wykresy słupkowe liczby ofert i liczby zgłoszeń (Rys. 17, 18) pozwalają porównać skalę

zjawisk i pokazują, że dzielnice o wysokiej przestępczości nie muszą mieć relatywnie wysokiej liczby ofert Airbnb.



Rysunek 17: Wykres słupkowy liczby ofert w poszczególnych dzielnicach.




Rysunek 18: Wykres słupkowy liczby zgłoszeń w poszczególnych dzielnicach.

### Interpretacja wyników

Agregacja na poziomie dzielnic pokazuje, że największa liczba ofert Airbnb koncentruje się w Brooklynie i na Manhattanie, co częściowo pokrywa się z wysoką liczbą zgłoszeń NYPD w tych dzielnicach. Jednocześnie przykład Bronxu wskazuje, że wysoka liczba przestępstw nie musi oznaczać wysokiej liczby ofert krótkoterminowego najmu. Wyniki sugerują, że zależności obserwowane na poziomie lokalnym nie zawsze przenoszą się wprost na poziom agregacji administracyjnej.

## 7.6 Analiza siatkowa: zależność gęstości Airbnb a gęstości przestępczości


Na wykresie heksagonalnym (Rys. 19) przedstawiono zależność pomiędzy liczbą ofert Airbnb a liczbą zgłoszeń NYPD w obrębie komórki siatki (400m), przy zastosowaniu skali logarytmicznej.



Rysunek 19: Hexbin - zależność pomiędzy liczbą ofert Airbnb a liczbą zgłoszeń NYPD w obrębie komórek siatki.

Dodatkowo przedstawiono rozkład liczby zgłoszeń NYPD w przedziałach liczby ofert Airbnb (0, 1–10, 11–100, 100+) za pomocą boxplotu (Rys. 20), co umożliwia porównanie median oraz rozproszenia zgłoszeń pomiędzy grupami komórek o różnej intensywności rynku Airbnb.





Rysunek 20: Boxplot - rozkład liczby zgłoszeń NYPD w przedziałach liczby ofert Airbnb.

## Interpretacja wyników

Wykres heksagonalny wskazuje na dodatnie współwystępowanie liczby ofert Airbnb oraz liczby zgłoszeń NYPD na poziomie komórek siatki. Boxplot potwierdza tę zależność: wraz ze wzrostem liczby ofert Airbnb w komórce rosną mediany oraz rozproszenie liczby zgłoszeń NYPD, przy czym komórki z kategorią 100+ charakteryzują się najwyższym poziomem aktywności zgłoszeń. Wyniki te sugerują współwystępowanie intensywnego rynku Airbnb i wysokiej aktywności kryminalnej w tych samych obszarach, jednak zależność ta ma charakter korelacyjny i nie implikuje przyczynowości.

## 7.7 Modele regresji

Oszacowano modele regresji liniowej metodą najmniejszych kwadratów, przyjmując logarytm ceny oferty (`log_price`) jako zmienną objaśnianą. Zmienna `borough` odpowiada podziałowi administracyjnemu na dzielnice, natomiast `room_type` kontroluje typ zakwaterowania.

### 7.7.1 Model bazowy

Model bazowy przyjmuje postać:

$$\log\_price_i = \beta_0 + \beta_1 \text{crimes\_total\_400m}_i + \gamma \text{borough}_i + \delta \text{room\_type}_i + \varepsilon_i. \quad (1)$$

Model wyjaśnia około 51% zmienności logarytmu ceny ( $R^2 = 0,511$ ,  $N = 31\,177$ ). Współczynnik przy `crimes_total_400m` jest dodatni i istotny statystycznie ( $\hat{\beta}_1 = 2,3 \cdot 10^{-5}$ ,  $p < 0,001$ ).

### 7.7.2 Model rozszerzony

Model rozszerzony uwzględnia rozbić przestępczości na kategorie oraz zmienne opisujące aktywność i dostępność:

$$\begin{aligned}\log\_price_i = & \beta_0 + \beta_1 felonies\_400m_i + \beta_2 violent\_400m_i \\ & + \beta_3 number\_of\_reviews_i + \beta_4 availability\_365_i \\ & + \gamma borough_i + \delta room\_type_i + \varepsilon_i.\end{aligned}\tag{2}$$

Dopasowanie modelu wzrasta do  $R^2 = 0,536$ , co wskazuje na istotną poprawę wyjaśnianej zmienności względem modelu bazowego.

### 7.7.3 Interpretacja wyników

W modelu bazowym dodatni i istotny współczynnik przy zmiennej `crimes_total_400m` wskazuje, że po kontroli lokalizacji oraz typu zakwaterowania wyższa liczba zgłoszeń NYPD współwystępuje z wyższymi cenami ofert Airbnb.

Model rozszerzony pokazuje, że po rozbiciu przestępczości na kategorie kierunek zależności różni się w zależności od typu zdarzeń. Liczba przestępstw typu *felony* wpływa dodatnio na `log_price`, natomiast liczba przestępstw typu *violent* wpływa ujemnie, przy zachowaniu istotności statystycznej obu efektów. Wynik ten sugeruje, że po kontroli czynników lokalizacyjnych rynek Airbnb reaguje negatywnie na przemoc, podczas gdy ogólna intensywność cięższych przestępstw może nadal odzwierciedlać atrakcyjność centralnych lokalizacji.

Zmienne kontrolne zachowują oczekiwane znaki: oferty typu *Private room* oraz *Shared room* są istotnie tańsze od *Entire home/apt*, większa dostępność w ciągu roku sprzyja wyższymi cenom, natomiast większa liczba opinii wiąże się z nieznacznie niższym poziomem cen, co może odzwierciedlać większą konkurencję w popularnych lokalizacjach.

## 8 Analiza sieciowa

Celem analizy sieciowej było uchwycenie globalnej struktury relacji pomiędzy Airbnb a przestrzenną przestępczością (NYPD). W przeciwieństwie do analizy promieniowej (liczba przestępstw w otoczeniu pojedynczej oferty), podejście sieciowe pozwala opisać, które obszary przestępczości są strukturalnie „współdzielone” przez wiele ofert Airbnb oraz czy w mieście istnieją spójne grupy hotspotów, które są powiązane z podobnym zestawem ofert.

### 8.1 Hotspoty przestępczości (agregacja siatkowa)

W pierwszym kroku wyznaczono hotspoty przestępczości na podstawie danych NYPD z lat 2018-2019. Zdarzenia zostały zagregowane do regularnej siatki przestrzennej poprzez zaokrąglanie współrzędnych geograficznych do kroku `GRID_SIZE = 0,005`, co odpowiada w przybliżeniu komórce o rozmiarze ok. 500 m. Każda komórka siatki, w której wystąpiło co najmniej jedno zgłoszenie, została potraktowana jako hotspot. Dla każdego hotspotu obliczono:

- `total_crimes` – liczba zdarzeń ogółem,

- **violent\_crimes** – liczba zdarzeń sklasyfikowanych jako **violent** (wg własnej taksonomii),
- **felony\_crimes** – liczba zdarzeń o kategorii prawnej *felony*.

W badanym zbiorze uzyskano **3097 hotspotów**.

## 8.2 Graf dwudzielny Airbnb-hotspot

Następnie zbudowano graf dwudzielny, w którym węzły należą do dwóch typów:

- **listing** – oferta Airbnb (węzeł: L\_<id>, atrybut: **price**),
- **hotspot** – komórka siatki przestępczości (węzeł: H\_<hotspot\_id>, atrybuty: **violent\_crimes**, **felony\_crimes**).

Krawędź pomiędzy ofertą a hotspotem istnieje, jeżeli oferta znajduje się w promieniu **DEFAULT\_RADIUS\_M** (400 m) od środka hotspotu. W grafie dodawano tylko te krawędzie, dla których dany hotspot ma **violent\_crimes** > 0. Ponadto wagę każdej krawędzi ustawiono na **violent\_crimes** danego hotspotu. Oznacza to, że graf dwudzielny reprezentuje relacje ofert z obszarami, gdzie występują zdarzenia typu **violent**.

W badanym zbiorze graf zawierał **34 274 węzły** oraz **66 478 krawędzi**.

## 8.3 Projekcja hotspotów

Aby przeanalizować zależności pomiędzy hotspotami, wykonano projekcję grafu dwudzielnego na warstwę hotspotów. W projekcji tej dwa hotspoty są połączone, jeżeli istnieje co najmniej jedna oferta Airbnb, która znajduje się w promieniu 400 m od obu hotspotów. Waga krawędzi w projekcji odpowiada liczbie wspólnych ofert Airbnb.

W badanym zbiorze projekcja zawierała **3097 węzłów** i **4527 krawędzi**. Największa składowa spójna (LCC) zawierała **1621 węzłów** i **3869 krawędzi**.

## 8.4 Miary centralności hotspotów

Dla sieci hotspotów, obliczono następujące miary centralności (na całej sieci, a miarę pośrednictwa wyłącznie dla największej składowej spójnej - LCC):

- *stopień centralności* – liczba połączeń hotspotu z innymi hotspotami,
- *siła* (ważony stopień) – suma wag krawędzi, interpretowana jako łączna liczba współdzielonych ofert Airbnb,
- *PageRank* (z wagami) – miara globalnej istotności hotspotu, wynikająca z jego powiązań z innymi ważnymi hotspotami w sieci,
- *pośrednictwo* (betweenness, na LCC) – rola hotspotu jako węzła pośredniczącego w przepływie ścieżek pomiędzy różnymi częściami sieci.

Przykładowo, najwyższe wartości PageRank osiągnęły hotspoty wymienione w Tab. 10. Interpretacyjnie: są to hotspoty, które łączą się z wieloma innymi hotspotami poprzez wspólne listingi i znajdują się w strukturze sieci w istotnych miejscach.

Tabela 10: Top hotspoty według PageRank (projekcja hotspotów).

| Hotspot          | degree_cent | PageRank | strength | betweenness_LCC |
|------------------|-------------|----------|----------|-----------------|
| H_40.765_-73.99  | 0,002584    | 0,001210 | 719      | 0,007579        |
| H_40.705_-74.01  | 0,001938    | 0,001195 | 382      | 0,000965        |
| H_40.635_-74.08  | 0,002261    | 0,001168 | 39       | 0,000000        |
| H_40.62_-74.03   | 0,002261    | 0,001108 | 36       | 0,001863        |
| H_40.865_-73.925 | 0,002584    | 0,001041 | 120      | 0,003170        |

Wysokie wartości PageRank/strength oznaczają hotspoty, które są współdzielone przez wiele ofert Airbnb oraz łączą regiony sieci. Tego typu węzły można interpretować jako obszary, których zmiana (np. wzrost/spadek natężenia przestępczości) potencjalnie wpływa na większą część rynku Airbnb, bo są strukturalnie istotne w relacjach przestrzennych.

## 8.5 Detekcja społeczności (community detection)

W kolejnym kroku wykonano detekcję społeczności na największej składowej spójnej (LCC). Zastosowano algorytm *greedy modularity communities* maksymalizujący modularność (waga krawędzi była uwzględniana). Podstawowe statystyki uzyskanego podziału społecznościowego przedstawiono w Tab. 11:

Tabela 11: Podsumowanie detekcji społeczności w sieci hotspotów (LCC).


| Miara               | Wartość |
|---------------------|---------|
| Liczba społeczności | 32      |
| Modularność (LCC)   | 0,8868  |
| Węzły w LCC         | 1 621   |
| Krawędzie w LCC     | 3 869   |

Tak wysoka modularność sugeruje, że sieć hotspotów ma wyraźnie modularną strukturę: istnieją grupy hotspotów mocniej powiązanych między sobą (dzielących liczne listingi Airbnb) niż z pozostałą częścią sieci.

## 8.6 Wizualizacje sieci i społeczności


Dla czytelności przygotowano wizualizację statyczną sieci hotspotów ograniczoną do 250 węzłów o najwyższym PageRank (Rys. 21). Takie ograniczenie jest konieczne, ponieważ pełna sieć (3097 węzłów) jest trudna do interpretacji wizualnej. Na wykresie węzły reprezentują hotspoty, a krawędzie - powiązania wynikające ze wspólnych listingów Airbnb.

Hotspot projection (LCC) - top 250 nodes by PageRank (colored by community)



Rysunek 21: Projekcja hotspotów (Top 250 wg PageRank).


Dodatkowo przedstawiono rozkład liczebności społeczności (Rys. 22), co pozwala ocenić, czy struktura składa się z wielu małych społeczności czy kilku dominujących klastrów.



Rysunek 22: Rozmiary wykrytych społeczności.

Przygotowano również interaktywną mapę społeczności (plik HTML), gdzie hotspoty są

pokolorowane wg `community_id`. Mapa umożliwia przełączanie warstw i sprawdzanie atrybutów hotspotów (liczba przestępstw ogółem, violent, felony).



Rysunek 23: Wizualizacja rozmieszczenia wykrytych społeczności.

Jeżeli społeczności są przestrzennie spójne (kolory tworzą „plamy” na mapie), sugeruje to, że wykryte klastry odpowiadają realnym regionom funkcjonalnym miasta (z punktu widzenia relacji Airbnb–hotspot).

## 8.7 Interpretacja wyników analizy sieciowej

Analiza sieciowa ujawniła, że relacje pomiędzy ofertami Airbnb a hotspotami przestępczości mają wyraźnie uporządkowaną i nielosową strukturę. Projekcja grafu dwudzielnego na warstwę hotspotów prowadzi do sieci o jednej dominującej składowej spójnej oraz licznych mniejszych komponentach, co wskazuje na istnienie obszarów silnie powiązanych poprzez wspólne oferty Airbnb.

Miary centralności pokazują istotne zróżnicowanie roli poszczególnych hotspotów w sieci. Hotspoty o wysokich wartościach *PageRank* oraz *strength* pełnią funkcję węzłów strukturalnie istotnych, ponieważ są współdzielone przez wiele ofert Airbnb i łączą różne części sieci. Takie obszary można interpretować jako kluczowe punkty styku pomiędzy rynkiem krótkoterminowego najmu a przestrzenną koncentracją przestępczości.

Wyniki detekcji społeczności wskazują na bardzo silną modułarną strukturę sieci, co potwierdza wysoka wartość modularności. Wykryte społeczności odpowiadają grupom hotspotów, które są intensywnie powiązane wewnątrz przez wspólne listingi Airbnb, a jednocześnie relatywnie słabo połączone z pozostałą częścią miasta. Rozkład liczebności społeczności sugeruje współistnienie kilku większych klastrów oraz wielu mniejszych, bardziej lokalnych struktur.

Wizualizacja przestrzenna społeczności pokazuje, że wykryte klastry są w dużej mierze spójne geograficznie i tworzą wyraźne plamy na mapie miasta. Sugeruje to, że struktura sieciowa nie jest jedynie artefaktem konstrukcji grafu, lecz odzwierciedla realne regiony funkcjonalne miasta z punktu widzenia relacji pomiędzy Airbnb a przestępczością.

## 9 Podsumowanie i wnioski

Celem projektu było porównanie lokalizacji ofert Airbnb z przestrzenną dystrybucją przestępczości w Nowym Jorku oraz zbadanie, czy lokalny poziom przestępczości wiąże się z cenami i rozmieszczeniem ofert krótkoterminowego najmu. Analizy eksploracyjne (mapy, hexbin oraz agregacja siatkowa) pokazały, że obszary o wysokiej gęstości ofert Airbnb często współwystępują z obszarami o dużej liczbie zgłoszeń NYPD, co można interpretować jako efekt centralności i wysokiej aktywności miejskiej. Jednocześnie zależność ta nie jest symetryczna: wiele obszarów o wysokiej przestępczości nie wykazuje porównywalnej intensywności rynku Airbnb.

W analizie statystycznej surowe porównania stref (tercyle) sugerowały wzrost cen wraz z natężeniem przestępczości, jednak wyniki należy interpretować jako korelacje wynikające m. in. z różnic lokalizacyjnych. Modele regresji potwierdziły znaczenie kontroli lokalizacji i typu zakwaterowania, a po rozbiciu przestępczości na kategorie uzyskano zróżnicowane kierunki wpływu: przestępstwa typu *violent* wiązały się z niższymi cenami (po kontroli czynników), podczas gdy *felony* pozostawały dodatnio skorelowane z ceną.

Analiza sieciowa uzupełniła wnioski lokalne o perspektywę globalną: projekcja hotspotów ujawniła modułarną strukturę miasta z wyraźnymi klastrami hotspotów współdzielonych przez oferty Airbnb. Wysokie wartości centralności identyfikują hotspoty strukturalnie istotne, potencjalnie wpływające na większą część rynku poprzez swoją pozycję w sieci powiązań przestrzennych.

Podsumowując, rynek Airbnb w Nowym Jorku koncentruje się w obszarach o wysokiej aktywności miejskiej, które jednocześnie cechują się dużą liczbą zgłoszeń kryminalnych, jednak po kontroli czynników lokalizacyjnych i segmentu rynku widoczna jest selektywna reakcja na typ przestępczości - szczególnie negatywna dla zdarzeń typu *violent* (o charakterze przemocy).